ДИФФЕРЕНЦИАЛЬНЫЕ УРАВНЕНИЯ И ПРОЦЕССЫ УПРАВЛЕНИЯ
N. 1, 2026
Электронный журнал,
рег. Эл № ФС77-39410 от 15.04.2010
ISSN 1817-2172

http://diffjournal.spbu.ru/
e-mail: jodiff@mail.ru

Прикладные задачи

Анализ ультразвуковых изображений щитовидной железы методами вейвлет-преобразования и локальной функции плотности

В. А. Лямин*, Ампилова Н.Б.**, Семенов А.А.***, Соловьев И.П.****

Санкт-Петербургский государственный университет

* st067898@student.spbu.ru
** n.ampilova@spbu.ru
*** arseny@thyro.ru
**** i.soloviev@spbu.ru

Аннотация. В работе рассматривается метод автоматизированного анализа ультразвуковых изображений щитовидной железы, основанный на комбинированном использовании вейвлет-преобразования Хаара, локальной функции плотности и текстурных признаков Харалика. Предложенный подход предполагает разбиение размеченных УЗИ-изображений на непересекающиеся блоки с последующим извлечением пространственно-частотных, мультифрактальных и статистических характеристик текстуры. В качестве классификатора использован метод опорных векторов (SVM). Проведено сравнительное исследование влияния размера блока и параметров используемых методов на качество классификации узловых образований. Показано, что наилучшие результаты достигаются при использовании блоков размером 32×32 пикселя и совокупности текстурных признаков Харалика с набором расстояний {1, 2, 3, 4}. Разработан программный комплекс, реализующий предложенные методы и позволяющий выполнять автоматическую разметку изображений. Полученные результаты демонстрируют перспективность применения комбинированного математического подхода для повышения точности диагностики узловых образований щитовидной железы.

Ключевые слова: ультразвуковая диагностика; щитовидная железа; анализ изображений; вейвлет-преобразование Хаара; локальная функция плотности; мультифрактальный спектр; текстурные признаки Харалика.

1. Введение

Ультразвуковая диагностика (УЗИ) является одним из ключевых методов визуализации, применяемых для раннего выявления патологий и оценки состояния тканей щитовидной железы. По сравнению с методами компьютерной и магнитно-резонансной томографии ультразвук обладает высоким разрешением, доступностью, безопасностью и возможностью многократного повторного использования без вреда для пациента. Одной из наиболее частых задач ультразвуковой диагностики является выявление и анализ узловых образований щитовидной железы, а также оценка морфологии и текстуры ткани.

Автоматизация обработки изображений УЗИ сталкивается с рядом трудностей: наличием шума, низким контрастом, размытостью границ узлов, неоднородностью акустического поля и высокой вариабельностью анатомических структур и плоскостей сканирования. Классические методы сегментации, такие как пороговые алгоритмы или метод K-средних, часто демонстрируют низкую устойчивость при работе с ультразвуковыми данными. Применение градиентных методов, использующих операторы Собеля, Лапласа, а также метод Кэнни, ограничено из-за шума и неоднозначности контуров [1].

В научной литературе представлен широкий спектр подходов к анализу ультразвуковых изображений щитовидной железы. В ряде работ [2, 3] использовались локальные бинарные шаблоны (LBP), нечёткие локальные бинарные шаблоны (FLBP), вейвлеты Габора и Ширлет-преобразование. Исследования показывают, что текстурные признаки могут быть эффективно применены для классификации различных морфологических структур [4, 5].

Другим направлением является применение вейвлет-преобразований, которые позволяют разложить изображение на компоненты различных масштабов и частот, что особенно полезно для выделения локальных неоднородностей. Работа Thakral, Manhas [6] демонстрирует, что вейвлет-признаки могут улучшать качество анализа по сравнению с классическими методами. В то же время большинство исследований использует одно семейство вейвлетов или небольшую размерность признаков, а также не учитывает локальный характер структуры ткани.

Активно развиваются фрактальные методы, применяемые для анализа сложной текстуры биологических объектов [7]. Фрактальные признаки хорошо подходят для описания неоднородности тканей, однако в анализе УЗИ они редко используются совместно с вейвлетами или текстурными признаками, что ограничивает информативность получаемых результатов исследований. Применение фрактальных методов для анализа ультразвуковых изображений рассматривается в работах [8, 9].

Многие исследования в этой области опираются на нейросетевое моделирование, часто использующее сверточные нейронные сети (CNN). Несмотря на хорошие результаты, эти методы требуют больших размеченных наборов данных, которые в области анализа УЗИ щитовидной железы доступны редко [10]. Кроме того, интерпретируемость глубоких моделей остаётся существенной проблемой.

Таким образом, возникает необходимость в разработке метода, который:

1. эффективно выделяет локальные особенности тканей, даже при низком контрасте и размытых границах;
2. устойчив к шуму и неоднородности тканей;
3. не требует большого объёма данных для обучения;
4. обеспечивает интерпретируемость результатов анализа.

В данной работе рассматривается подход, основанный на комбинированном использовании трёх групп признаков:

- вейвлет-преобразования Хаара [11], обеспечивающего пространственно-частотное разложение изображения;

- локальной функции плотности [12], используемой для оценки неоднородности мелкомасштабных структур;
- текстурных признаков Харалика [13], описывающих статистические характеристики.

Предлагается единая схема извлечения признаков на основе рассмотрения локальных блоков изображения, что позволяет учитывать мелкие детали структуры ткани и повышает точность анализа. Представлен программный комплекс, реализующий описанные методы и предназначенный для автоматизированной обработки ультразвуковых изображений и генерации признаков для последующей классификации.

2. Данные и методы. Обработка изображений

Для проведения исследования были использованы изображения УЗИ щитовидной железы, полученные в Клинике высоких медицинских технологий им. Н. И. Пирогова (Санкт-Петербург). Эти изображения были предварительно размечены специалистами клиники, затем из них мы сформировали обучающее множество.

В исследовании рассматривались гиперэхогенные (более светлые на изображении по сравнению с окружающей тканью щитовидной железы), гипохогенные (наиболее распространенные, более тёмные на изображении по сравнению с окружающей тканью) и анэхогенные (практически не отражающие ультразвук, «черные») узлы, поскольку они заметно отличаются по плотности (а значит, и по яркости на изображении) от окружающей ткани, что делает их более доступными для автоматического анализа.

Изоэхогенные узлы, которые в клинической практике обозначают узлами с «пониженной эхогенностью» и имеют яркость, схожую с окружающей тканью, в данной работе не рассматривались. Они требуют более сложных методов анализа, поэтому в представленном исследовании такие узлы трактовались как гипоэхогенные.

Размер анализируемых изображений составляет 1024x768 пикселей. Изображение разбивается на области (блоки) подходящего размера (далее мы эмпирически выбираем размер 32x32 пикселя). В последующем тексте единица измерения опускается.

Области выбирались так, чтобы итоговое множество областей оказалось максимальным по количеству и при этом области не пересекались друг с другом. При использовании блока размером 32×32 из изображений удаётся получить около 1000 блоков.

На рисунке 1 показан пример получения таких областей. Для увеличения резкости изображения были предварительно отфильтрованы методом Лапласа.

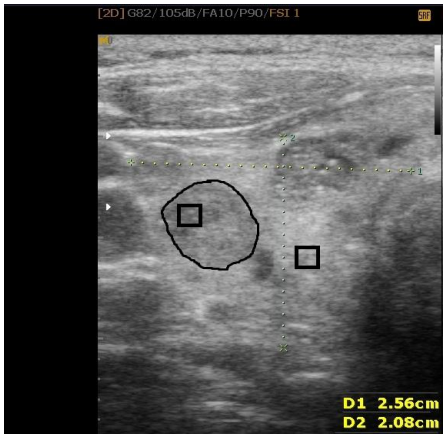

Рис. 1. Изображение УЗИ щитовидной железы с одним очерченным узлом и двумя квадратными блоками, выбранными из нормальной (квадратная область вне обведенного участка) и узловой ткани щитовидной железы (квадратная область внутри обведенного участка)

3. Вейвлет-преобразование

Одним из самых простых и исторически первых является вейвлет Хаара [14]. Его ключевая идея — разложить сигнал на низкочастотную (гладкую, аппроксимационную) часть и высокочастотную (детализирующую) часть. Для этого сигнал пропускают через два фильтра: низких частот (L) и высоких частот (H).

Одномерный случай

Одномерное дискретное вейвлет-преобразование разбивает сигнал на два набора коэффициентов:

- L — аппроксимация, показывает усреднённую структуру сигнала и показывает низкие частоты;
- H — детали, показывают колебания, резкие изменения и границы, высокие частоты.

Для массива значений $x = [x_0, x_1, \dots, x_N]$, где N — степень двойки, разложение выполняется так:

- $H_i = \frac{x_{2i} - x_{2i+1}}{\sqrt{2}}$;
- $L_i = \frac{x_{2i} + x_{2i+1}}{\sqrt{2}}$.

Это значит, что каждый шаг одновременно «усредняет» соседние элементы (формируя низкие частоты) и вычисляет разность между ними (формируя высокие частоты). Например, исходный одномерный сигнал (дискретная последовательность значений): [10, 12, 9, 5, 20, 18, 3, 2], после преобразования Хаара имеет вид:

- L = [15.56, 9.89, 26.87, 3.54]
- H = [–1.41, 2.83, 1.41, 0.71]

Видно, что в полученных данных:

- L содержит общий «силуэт» сигнала
- H содержит изменения между соседними элементами.

Двумерный случай (для изображений)

Двумерное вейвлет-преобразование применяет тот же принцип сначала к строкам, затем к столбцам [15]. В результате на данном этапе формируются четыре матрицы:

- LL — низкие частоты по обеим осям;
- LH — низкие частоты по горизонтали, высокие по вертикали;
- HL — высокие частоты по горизонтали, низкие по вертикали;
- HH — высокие частоты по обеим осям.

Например, для изображения размером 32×32 одномерное преобразование Хаара сначала выполняется по строкам. Каждая строка преобразуется в аппроксимационные (L) и детализирующие (H) коэффициенты длиной по 16 элементов (половина исходной длины строки). После обработки всех строк формируется новая матрица 32×32, в которой первая половина каждого ряда содержит коэффициенты L, а вторая половина — коэффициенты H. Именно к этой полученной матрице затем применяется такое же преобразование по столбцам.

В результате первый уровень разложения формирует четыре матрицы коэффициентов: LL, HL, LH, HH. Матрица LL имеет размер 16x16. Далее процесс рекурсивно повторяется только для области LL, пока она не уменьшится до одного пикселя. В качестве признаков используются коэффициенты матриц LL, HL, LH, HH.

Для примера возьмем изображение 4 на 4 и выполним описанное преобразование. В настоящем примере для наглядности коэффициенты вычисляются с делением на 2. Использование деления на 2 вместо $\sqrt{2}$ не меняет структуру (распределение низко- и высокочастотных компонент), а влияет только на масштаб коэффициентов.

$$\begin{pmatrix} 10 & 14 & 12 & 8 \\ 6 & 2 & 4 & 8 \\ 10 & 10 & 14 & 14 \\ 2 & 6 & 4 & 8 \end{pmatrix} \rightarrow \begin{pmatrix} 12 & 10 & -2 & 2 \\ 4 & 6 & 2 & -2 \\ 10 & 14 & 0 & 0 \\ 4 & 6 & -2 & -2 \end{pmatrix}$$

Для примера поясним, как выполнялось преобразование для первой строки:

- L1 = (10 + 14) / 2 =12;
- H1 = (10 − 14) / 2 = −2;
- L2 = (12 + 8) / 2 = 10;
- H2 = (12 − 8) / 2 = 2.

Далее применяем одномерный метод Хаара к каждому столбцу полученной матрицы. Берём пары строк (1,2) и (3,4) в каждом столбце. Например, для первого столбца получаем:

- пара (12, 4): L = (12 + 4) / 2 = 8, H = (12 − 4) / 2 = 4;
- пара (10, 4): L = (10 + 4) / 2 = 7, H = (10 − 4) / 2 = 3.

В результате получаем матрицу:

$$\begin{pmatrix} 8 & 8 & 0 & 0 \\ 7 & 10 & -1 & -1 \\ 4 & 2 & -2 & 2 \\ 3 & 4 & 1 & 1 \end{pmatrix}$$

Новая матрица состоит из четырех компонентов:

$$\text{LL} = \begin{pmatrix} 8 & 8 \\ 7 & 10 \end{pmatrix}, \text{LH} = \begin{pmatrix} 4 & 2 \\ 3 & 4 \end{pmatrix}, \text{HL} = \begin{pmatrix} 0 & 0 \\ -1 & -1 \end{pmatrix}, \text{HH} = \begin{pmatrix} -2 & 2 \\ 1 & 1 \end{pmatrix}$$

На рисунке 2 показан пример выполнения метода Хаара на изображении 64 x 64. Данный способ эффективен за счет разделения деталей изображения по направлениям (горизонтальное, вертикальное и диагональное).

Матрица LL раскладывается пока не будет получено изображение размером в один пиксель. На каждом шаге n алгоритма разложения вычисляется энергия для матриц HL_n, LH_n, HH_n по формуле

$$E = \sum_i \sum_j C_{ij}^2, \tag{3}$$

где C_{ij} − элементы поддиапазонных матриц HL_n, LH_n, HH_n, являющиеся вейвлет-коэффициентами соответствующего уровня разложения. Коэффициенты этих матриц характеризуют вклад соответствующих частотных компонент сигнала). Эти значения энергии составляют вектор признаков для обучения модели.

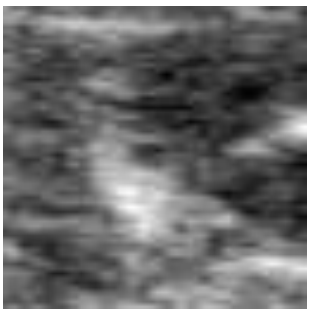

1

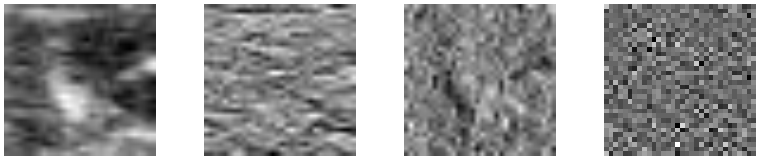

2 3 4 5

Рис. 2. Вычисление матриц LL (2), LH (3), HL (4), HH (5) на изображении узла 64 на 64 (1)

4. Локальная функция плотности

Этот метод позволяет определить текстуру изображения путем вычисления для каждого пикселя некоторой характеристики, называемой локальной функцией плотности и рассмотренной впервые в работе [7]. Также пример применения этого метода был подробно рассмотрен в статьях [12, 16].

Для произвольной точки x обозначим за x центр окрестности B(x, r), а за r ее радиус. В качестве окрестности выбираются квадраты с центром в точке x и стороной 2r. Также обозначим за μ меру окрестности. Предположим, что

$$\mu\big(B(x,r)\big) = kr^{d(x)},$$

где *d(x)* так называемая локальная функция плотности. Заметим, что это предположение является частным случаем так называемого степенного закона, который часто подтверждается на практике и является основным для фрактальных методов. Прологарифмируем это равенство и затем перейдем к пределу:

$$d(x) = lim_{r\to 0}\frac{ln\mu\big(B(x,r)\big)}{lnr}.$$

Функция *d(x)* характеризует степень неоднородности распределения интенсивностей пикселей в окрестности x. В качестве меры окрестности выбирается сумма яркостей пикселей, входящих в нее. Точки x с некоторым заданным значением локальной плотности α образуют множества уровня

$$E_\alpha = \{x \in I: d(x) = \alpha\}.$$

Поскольку число точек на изображении конечно, вычисляем $\alpha_{min}, \alpha_{max}$. Чтобы уменьшить число множеств уровня на практике обычно рассматривают множества вида

$$E_\alpha = \{x \in I: d(x) \in [\alpha, \alpha + \varepsilon)\},$$

где шаг ε определяется экспериментально. Таким образом, все изображение разбивается на непересекающиеся множества уровня. Мы можем интерпретировать их как бинарные изображения. Параметр ε определяет их количество. Вычисляя набор емкостных размерностей

для множеств уровня, получаем мультифрактальный спектр. В качестве признаков для обучения модели используется мультифрактальный спектр и значения середин диапазонов $[\alpha, \alpha + \varepsilon)$

5. Применение текстурных признаков Харалика

Применение текстурных признаков Харалика основано на предположении, что текстурная информация изображения определяется пространственными взаимосвязями между интенсивностями пикселей в полутоновом изображении. Эти взаимосвязи представляются в виде матриц, отражающих различные типы отношений между пикселями в заданной окрестности [17]. Далее из этих матриц извлекаются численные признаки для последующего анализа.

Для корректной работы данного метода необходимо выбрать область на изображении в виде прямоугольника, где N_x — количество пикселей по горизонтали и N_y — количество пикселей по вертикали, а N_g — количество уровней серого. Далее вводим горизонтальную пространственную область $L_x = \{1, \dots, N_x\}$ и вертикальную пространственную область $L_y = \{1, \dots, N_y\}$, а также множество уровней серого $G = \{1, \dots, N_g\}$. Основываясь на введенных понятиях, определим функцию изображения I следующим образом: $I: L_y \times L_x \to G$

Основным этапом реализации данного метода является вычисление четырех матриц частот P, отражающих отношения соседства между пикселями в окрестности, определяемой расстоянием d и выбранным направлением. Рассматриваются горизонтальное, вертикальное и диагональные направления. Интенсивности пикселей становятся индексами в формируемых матрицах, которые определяются следующим образом:

- $P_{d,0^\circ}(i,j) = \{((k,l),(m,n)) \in (L_y \times L_x) \times (L_y \times L_x) \mid k - m = 0, |\, l - n \,| = d, I(k,l) = i, I(m,n) = j\}$
- $P_{d,45^\circ}(i,j) = \{(k,l),(m,n)) \in (L_y \times L_x) \times (L_y \times L_x) \mid (k - m = d, l - n = -d) \vee (k - m = -d, l - n = d), I(k,l) = i, I(m,n) = j\}$
- $P_{d,90^\circ}(i,j) = \{(k,l),(m,n)) \in (L_y \times L_x) \times (L_y \times L_x) \mid k - m \mid = d, l - n = 0, I(k,l) = i, I(m,n) = j\}$
- $P_{d,135^\circ}(i,j) = \{((k,l),(m,n)) \in (L_y \times L_x) \times (L_y \times L_x) \mid (k - m = d, l - n = d) \vee (k - m = -d, l - n = -d), I(k,l) = i, I(m,n) = j\}$

где # обозначает мощность множества.

На следующем этапе полученные матрицы нормируются таким образом, чтобы сумма всех элементов равнялась единице. Для нормированных матриц p вычисляем математическое ожидание по строкам и столбцам (μ_x, μ_y), а также дисперсии (σ_x, σ_y) [18] по приведенным ниже формулам, индексы для матриц в формулах естественным образом опускаем:

- $\mu_x = \sum_{i=1} i \sum_{j=1} p\,(i,j)$
- $\mu_y = \sum_{i=j} j \sum_{i=1} p\,(i,j)$
- ${\sigma^2}_x = \sum_{i=1} (\,i - \mu_x)^2 \sum_{j=1} p\,(i,j)$
- ${\sigma^2}_y = \sum_{j=1} (\mathrm{j} - \mu_y)^2 \sum_{i=1} p\,(i,j)$

Для нормированных матриц p вычисляются 15 признаков, которые можно использовать при дальнейшем исследовании изображения. В наших экспериментах наилучшие результаты получаются при использовании следующих признаков: однородность, контраст, корреляция, дисперсия, гомогенность.

- $f_1 = \sum_i \sum_j p\,(i,j)^2$ — однородность. Это текстурный признак, который характеризует однородность текстуры изображения. Близкое к единице значение данного признака говорит о гладкой структуре, т.е. значения пикселей мало вариативны и часто повторяются.
- $f_2 = \sum_{n=0}^{N_g-1} n^{\,2} \left(\sum_{|i-j|\,=\,n}^{N_g} p\,(i,j)\right)$ — контраст. Данный признак показывает насколько сильно отличаются интенсивности соседних пикселей.
- $f_3 = \frac{\sum_i \sum_j ijp(i,j) - \mu_x \mu_y}{\sigma_x \sigma_y}$ — корреляция. Она измеряет степень линейной зависимости между значениями интенсивностей пикселей, расположенных рядом. Например, низкая корреляция указывает на наличие резких границ и высокочастотных изменений в изображении.
- $f_4 = -\sum_i \sum_j p\,(i,j) log(p(i,j))$ — энтропия Шеннона. Данный признак измеряет степень беспорядка или сложности текстуры на изображении.
- $f_5 = \sum_i \sum_j \frac{1}{1+(i-j)^2} p(i,j)$ — гомогенность. Это признак измеряет, насколько близки значения пикселей друг к другу. В ходе экспериментов было выявлено, что он наиболее сильно влияет на точность модели (до 70%).

6. Обучение нейронных сетей

Для применения методов машинного обучения были сформированы вектора признаков, состоящие из вычисленных текстурных характеристик для каждого блока по отдельности. В качестве модели машинного обучения был выбран метод опорных векторов (SVM) библиотеки scikit-learn [19], так как данная модель имеет простой API и эффективна на малых и средних выборках. Перед обучением признаки были приведены к единому масштабу, чтобы избежать доминирования одних признаков над другими. В частности, это освобождает от необходимости использования дополнительных метрик, ориентированных на оценку дисбаланса классов. Это особенно важно для SVM, поскольку алгоритм чувствителен к масштабу данных: расстояния между объектами и вычисление границ разделения напрямую зависят от значений признаков. Без нормализации доминирующие признаки могут необоснованно смещать положение разделяющей гиперплоскости, что снижает качество классификации. Масштабирование состоит в приведении каждого признака к диапазону [0, 1]. Преобразование выполняется по следующей формуле: $x_{scaled} = \frac{x - x_{min}}{x_{max} - x_{min}}$, где x_{min} и x_{max} — минимальное и максимальное значения данного признака соответственно. Данные были разделены на две группы: обучающая выборка составляла 80% данных, тестовая — 20%. Результаты всех экспериментов приведены на тестовой выборке.

7. Результаты экспериментов

7.1 Вейвлет Хаара

В наших экспериментах по анализу ультразвуковых изображений щитовидной железы были исследованы два варианта размера блока: 16×16 и 32×32 (таблица 1). После вычисления вейвлет-коэффициентов для каждого блока и формирования пространства признаков была проведена оценка точности модели SVM. Результаты показали, что использование меньшего блока (16×16) приводит к недостаточной информативности коэффициентов разложения: часть мелких текстурных особенностей сохраняется, но глобальная структура узлового участка теряется. Это выражается в пониженной итоговой точности классификации.

Наилучший результат был получен при размере блока 32×32, что согласуется с общей практикой анализа медицинских изображений, где требуется баланс между сохранением низкочастотных характеристик ткани и детализацией границ узла. Этот размер обеспечивает более

устойчивые признаки, извлекаемые из диапазонов LL, LH, HL и HH, и максимальную точность бинарной классификации «узел / нормальная ткань».

Таким образом, мы видим, что среди исследованных параметров оптимальным является использование блоков 32×32, поскольку именно при таком размере вейвлет-преобразование Хаара позволяет получать наиболее различимые области изображения, обеспечивающие наилучшую работу модели классификации. Во всех экспериментах для оценки точности моделей использовались следующие метрики:

- Accuracy — доля правильно классифицированных программной системой блоков (содержат ткань узла) от их общего числа в выборке;
- Precision — доля блоков, правильно классифицированных как содержащие ткань узла, среди всех правильно классифицированных;
- Recall — доля блоков, содержащих ткань узла, которые были корректно выявлены программной системой как блоки с узлом, среди всех блоков с узлами (полнота).

Таб. 1. Значения метрик в зависимости от размера области (S)

S	Accuracy	Precision	Recall
16x16	0.93	0.71	0.97
32x32	0.94	0.8	0.94

7.2. Локальная функция плотности

Для проведения исследования был взят такой же набор данных, как и для метода Хаара. При реализации данного метода были вычислены значения локальной функции плотности для каждой точки путем применения метода наименьших квадратов. Эксперименты показывают, что точность модели зависит от количества множеств E_α, то есть от способа разбиения диапазона значений функции плотности на интервалы. Чтобы упростить использование программы, каждый блок изображения разбивался на заданное число множеств уровня. Заметим, что поскольку диапазоны значений локальной функции плотности различны для разных блоков, фиксирование числа множеств уровня приводит к тому, что шаг ε меняется от блока к блоку.

В качестве признаков для обучения модели SVM использовались:

- средние значения диапазонов значений функции плотности для множеств уровня;
- мультифрактальный спектр.

Результаты приведены в таблице 2. Наибольшей точности модели удалось достичь при количестве множеств уровня 7.

Таб. 2. Доля правильно классифицированных объектов в зависимости от количества множеств уровня (N)

N	Accuracy	Precision	Recall
4	0.91	0.94	0.83
5	0.92	0.95	0.83
6	0.92	0.96	0.85
7	0.93	0.97	0.88
8	0.88	0.95	0.77
9	0.89	0.98	0.79
10	0.9	0.98	0.8

На рисунке 3 показана область узла щитовидной железы и семь изображений множеств уровня. Видно, что наиболее информативными оказываются множества уровня 3–6. На таблице 3 показаны значения емкостных размерностей для каждого множества уровня.

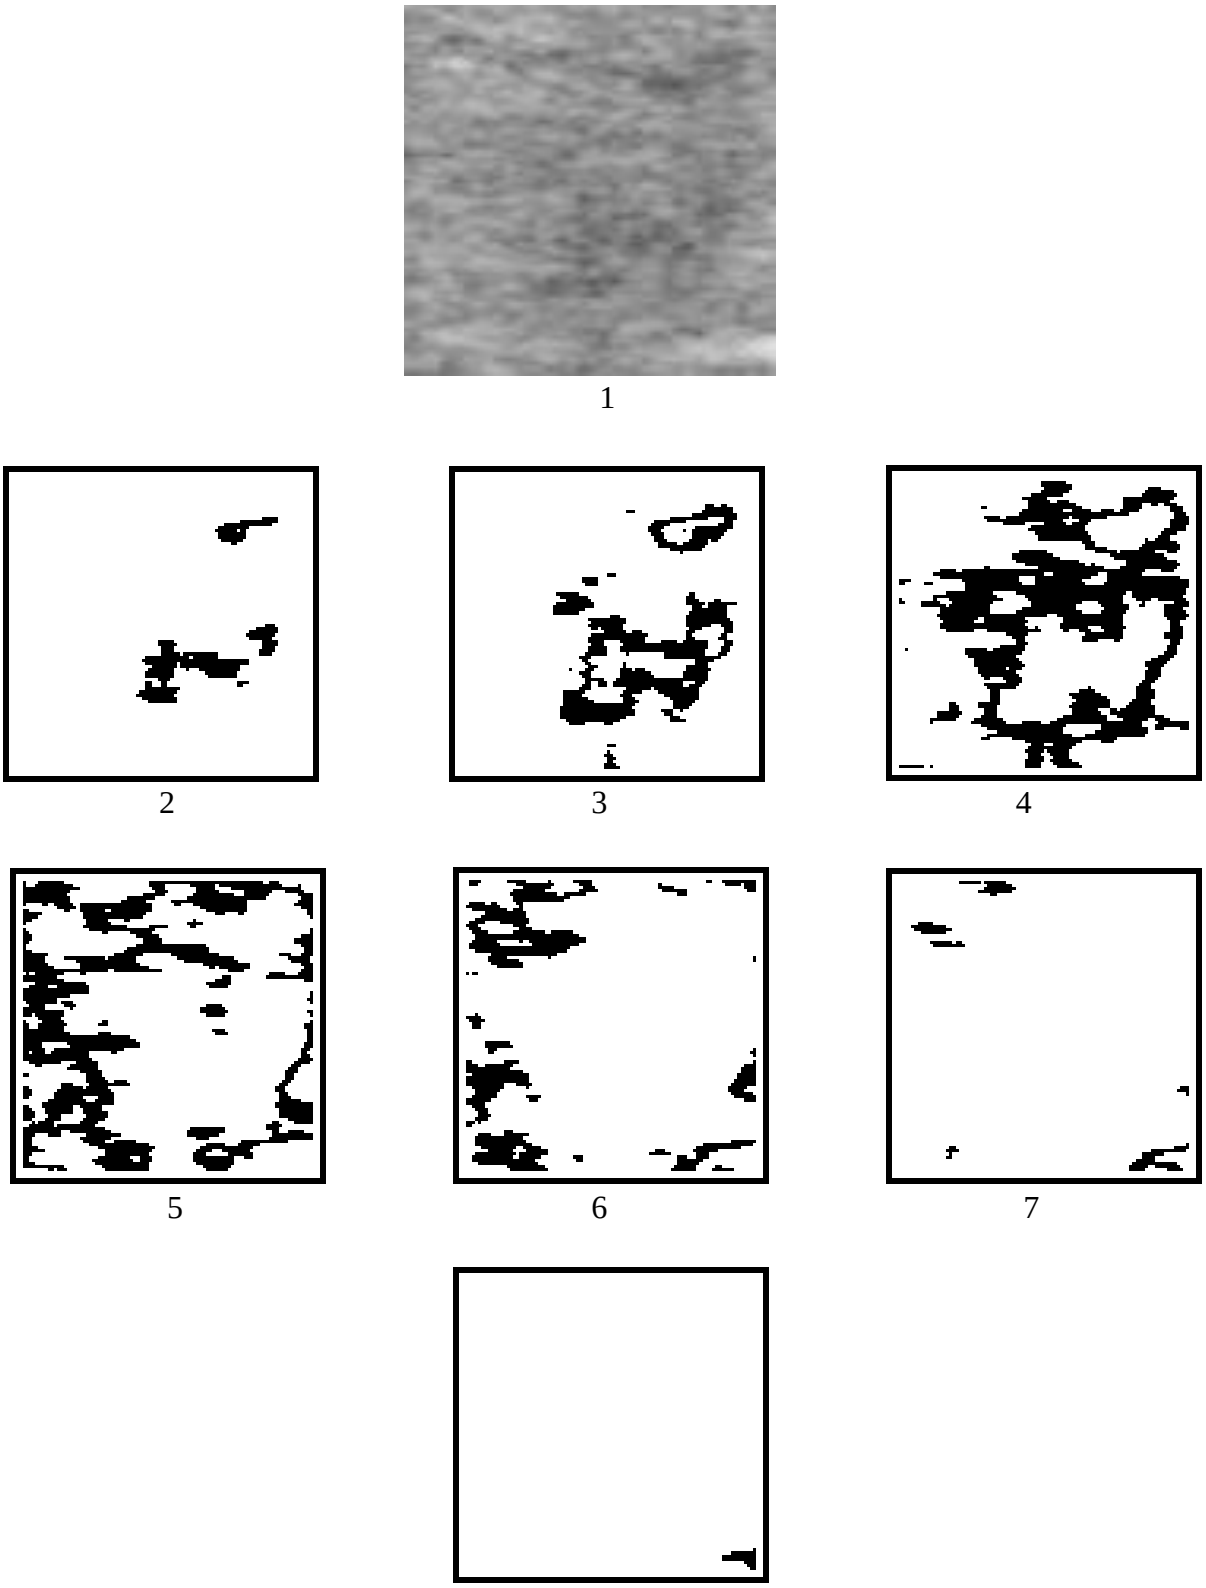

Рис. 3. Вычисления семи множеств уровня 2–8 по области узла щитовидной железы 1

Таб. 4. Емкостные размерности для множеств уровня

Множество уровня	Интервал	Емкостная размерность
2	[5.2, 5.6)	1.28
3	[5.6, 6)	1.58
4	[6, 6.4)	1.79
5	[6.4, 6.9)	1.78
6	[6.9, 7.3)	1.59
7	[7.3, 7.7)	1.16
8	[7.7, 8.1)	0.62

7.3 Текстурные признаки Харалика

На первом этапе экспериментов был определён оптимальный набор дистанций d для получения наилучших результатов обучения модели. Для этого признаки, рассчитанные при различных значениях d, объединялись в один вектор. В результате экспериментов оптимальным оказался набор расстояний {1, 2, 3, 4}. Итоговые значения приведены в таблице 5.

Таб. 5. Доля правильно классифицированных объектов в зависимости от d

d	Accuracy	Precision	Recall
1	0.95	0.86	0.91
1, 2, 3, 4	0.98	1	0.93
1, 2, 3, 4, 5	0.95	0.86	0.91

На втором этапе исследовался оптимальный размер извлекаемой области. В серии экспериментов рассматривались квадратные области размером 25×25, 32×32 и 35×35. Согласно результатам (таблица 6), наибольшей точности — доли правильных предсказаний среди всех предсказаний модели — удалось достичь при размере области 32×32 пикселя.

Таб. 6. Доля правильно классифицированных объектов в зависимости от размера блока (S)

S	Accuracy	Precision	Recall
25x25	0.90	0.95	0.83
32x32	0.98	1	0.93
35x35	0.92	0.96	0.85

8 Разметка изображения

Так как наилучшие результаты экспериментов показали текстурные признаки Харалика, то разметку изображения УЗИ щитовидной железы было решено провести на основании полученных данных от данного метода. Программа имела информацию лишь о принадлежности блока к щитовидной железе и должна была определить, является ли данный блок узлом или нормальной тканью. Для сравнения представлены также изображения, размеченные специалистом: на рисунке 4 показан пример с узлом, на рисунке 5 — без узла. Сравнение ручной и автоматической разметок позволяет наглядно оценить работу системы. Видно, что в первом случае система допустила одну ошибку, во втором примере разметило изображение без ошибок.

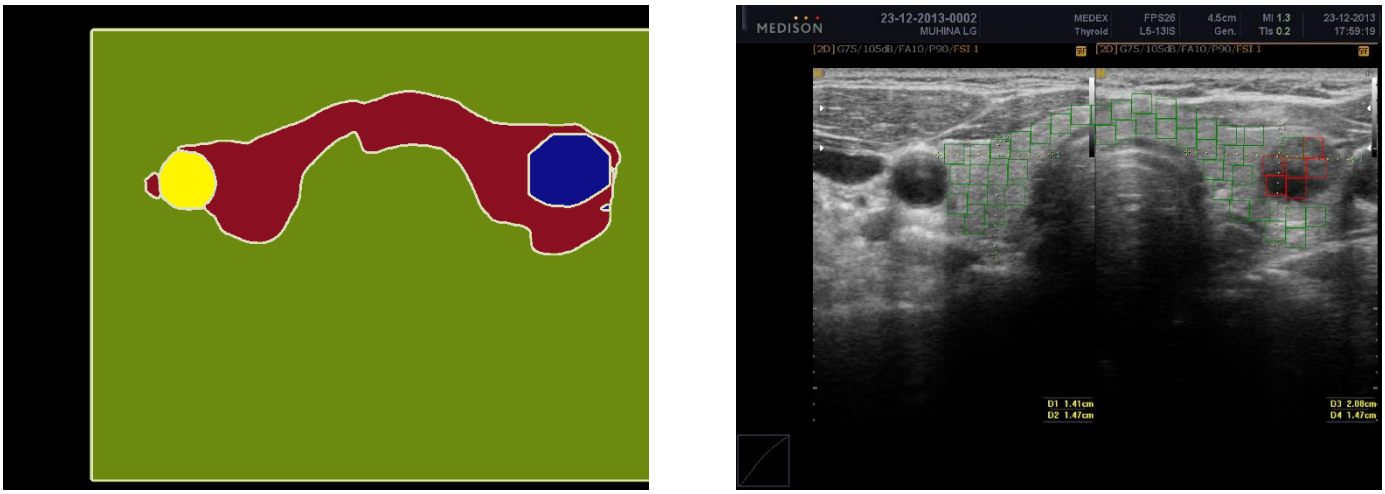

1 2

Рис. 4. Пример разметки изображения с узлом щитовидной железы. На изображении 1 показана разметка, выполненная специалистом. Красным цветом обозначена нормальная ткань, синим — узел, жёлтым — артерия, зелёным — остальная ткань. На изображении 2 представлена разметка того же изображения, выполненная программной системой: зелёным цветом обозначена нормальная ткань, а красным — узел.

1 2

Рис. 5. Пример разметки изображения без узла. Размеченное изображение 1 без узла щитовидной железы. Красный цвет — нормальная ткань, желтый — артерия, зеленый — остальная ткань. На изображении 2 показана разметка того же изображения системой, где зеленый — нормальная ткань, а красный — узел.

9 Программная реализация

Для практической реализации вышеописанных методов было написано программное приложение на языке C#.

Код для обучения модели был реализован на языке Python, поскольку он предоставляет широкий набор специализированных библиотек для машинного обучения.

Приложение включает все необходимые функции обработки изображений, вычисления характеристических признаков, человеко-машинный интерфейс, помогающий специалисту медику выявлять наиболее вероятных пациентов с патологией. Также, благодаря разбиению на блоки, в приложении реализована возможность локализации узла на изображении.

Заключение

В данной статье представлен подход к анализу и классификации изображений щитовидной железы, основанный на совместном использовании трех различных математических методов. Предлагаемый метод состоит в разбиении предварительно размеченных изображений УЗИ щитовидной железы на множество непересекающихся блоков для последующего извлечения численных характеристик при помощи вейвлет-преобразования, локальной функции плотности и текстурных признаков Харалика. Полученные признаки были использованы в качестве обучающего набора для нейросетевой модели по методу опорных векторов. Для практического использования данного подхода нами было реализовано программное приложение, которое позволяет наглядно проводить разметку узлов щитовидной железы.

Результаты данного исследования могут быть использованы в условиях медицинской клиники для раннего обнаружения пациентов, нуждающихся в первоочередной лечебной помощи.

Благодарности

Авторы благодарят Клинику высоких медицинских технологий им. Н.И. Пирогова за предоставленные образцы изображений.

Литература

[1] Vivian Bass, Julieta Mateos, Ivan M. Rosado-Mendez, Jorge Márquez Ultrasound image segmentation methods: A review // PROCEEDINGS OF THE XVI MEXICAN SYMPOSIUM ON MEDICAL PHYSICS — 2021

[2] Stamos Katsigiannis, Eystratios Keramidas, Dimitris Maroulis Local Binary Patterns: New Variants and Applications of Ultrasound Images and Videos January 2014 149–175.

[3] Агафонов А.В, Рожина Д.С, Гудков В.Ю. Модификация фильтра Габора для применения к цифровым изображениям дактилоскопических узоров, Евразийский научный журнал, 2017,№ 8, 7-10.

[4] Dimitris K. Iakovidis a, Eystratios G. Keramidas b, Dimitris Maroulis Fusion of fuzzy statistical distributions for classification of thyroid ultrasound patterns // Artificial Intelligence in Medicine 50 (2010) 33–41.

[5] Masashi Koga, Cheng-Lin Liu, Hiromichi Fujisawa Gabor Feature Extraction for Character Recognition: Comparison with Gradient Feature , Document Analysis and Recognition — 2005.

[6] Thakral S., Manhas P. (2019). Image Processing by Using Different Types of Discrete Wavelet Transform. // Advanced Informatics for Computing Research. ICAICR 2018. Communications in Computer and Information Science, vol 955. Springer, Singapore.

[7] Xu Y., Ji H. & Fermüller C. Viewpoint Invariant Texture Description Using Fractal Analysis International Journal of Computer Vision. 2009, V. 83, № 1. p. 85-100.

[8] Chen DR, Chang RF, Chen CJ, Ho MF, Kuo SJ, Chen ST, Hsu HC. Classification of breast ultrasound images using fractal feature // Clinical Imaging. – 2005. – T.29, №4. – C.235–245

[9] Zhuang Z., Lei N., Raj A. N. J., Qiu S. Application of fractal theory and fuzzy enhancement in ultrasound image segmentation // Medical & Biological Engineering & Computing. – 2019. – Vol.57, №3. – P.623–632.

[10] Zheng T., Qin H., Cui Y., Wang R., Zhao W., Zhang S., Geng S., Zhao L. (2023). Segmentation of thyroid glands and nodules in ultrasound images using the improved U-Net architecture. // BMC Medical Imaging

[11] Haar A., “Zur Theorie der orthogonalen Funktionensysteme”, Math. Ann., 69:3 (1910), 331–371

[12] N. B. Ampilova, I. P. Soloviev, and V. A. Lyamin, “Application of fractal methods to the analysis of biocrystal images,” *Journal of Applied Electromagnetism*, vol. 25, no. 2, pp. 11–20, Dec. 2023.

[13] Haralick R.M., Shanmugam K., Dinstein I. Textural features for image classification // IEEE Transactions on systems, man and cybernetics. 1973. Vol. SMC 3. № 6. P. 610-621.

[14] Audithan S., Chandrasekaran RM. Document Text Extraction from Document Images Using Haar Discrete Wavelet Transform // European Journal of Scientific Research ISSN 1450-216X Vol.36 No.4 (2009), pp.502-512

[15] J. M. Shapiro, Embedded image coding using zerotrees of wavelet coefficients // IEEE Transactions on Signal Processing, vol. 41, no. 12, pp. 3445–3462, Dec. 1993

[16] I. Soloviev Application of multifractal methods for the analysis of crystal structures // Journal of applied electromagnetism. -- 2022. -- T. 24. -- C. 21-26.

[17] Haralick R.M. Statistical and structural approaches to texture // Proceedings of the IEEE. 1979. Vol. 67, №.5. P. 786 - 804.

[18] Ю. В. Конкин, А. Н. Колесенков Распознавание изображений на основе текстурных признаков Харалика и искусственных нейронных сетей // Известия Тульского государственного университета. Технические науки. - 2016. - № 2. - С. 117-123.

[19] Pedregosa, F., Varoquaux, G., Gramfort, A. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

Analysis of Thyroid Ultrasound Images by Using Wavelet Transform and Local Density Function Method

V. A. Lyamin*, N. B. Ampilova**, A. A. Semenov***, I. P. Soloviev****

Saint Petersburg State University

* st067898@student.spbu.ru
** n.ampilova@spbu.ru
*** arseny@thyro.ru
**** i.soloviev@spbu.ru

Abstract. This paper presents an automated approach for the analysis of thyroid ultrasound images, which is based on a combination of the Haar wavelet transform, local density function, and Haralick texture features. The proposed method includes partitioning the annotated ultrasound images into non-overlapping blocks followed by extraction of spatial-frequency, multifractal, and statistical texture characteristics. For tissue classification Support Vector Machine (SVM) classifier is used. To evaluate the influence of block size and feature extraction parameters on classification performance a comparative study was conducted. The experimental results demonstrate that the best performance is achieved by using 32×32 pixel blocks and the Haralick texture features computed with a distance set {1, 2, 3, 4}. To perform automated image labeling the software system implementing the proposed algorithms was developed. The obtained results confirm the effectiveness of the combined mathematical approach for improving the diagnostic accuracy of the thyroid nodule detection.

Keywords: ultrasound imaging; thyroid gland; image analysis; Haar wavelet transform; local density function; multifractal analysis; Haralick texture features.

Acknowledgement

The authors would like to thank the N. I. Pirogov Clinic of High Medical Technologies for providing the image samples.