




ДИФФЕРЕНЦИАЛЬНЫЕ
УРАВНЕНИЯ
И
ПРОЦЕССЫ УПРАВЛЕНИЯ

№ 2, 2026

Электронный журнал,
рег. Эл № ФС77-39410 от 15.04.2010
ISSN 1817-2172

<http://diffjournal.spbu.ru/>
e-mail: jodiff@mail.ru

Машинное обучение и искусственный интеллект в процессах управления

Интерпретируемый прогноз рецидива рака щитовидной железы на основе якорных локальных метрик и минимального набора правил

Дюк В.А.

Институт проблем транспорта им. Н.С. Соломенко Российской академии наук

v_duke@mail.ru

Аннотация. Прогноз рецидива дифференцированного рака щитовидной железы остаётся важной клинической задачей, несмотря на высокую эффективность современных методов лечения. Современные модели машинного обучения, включая ансамблевые алгоритмы (Random Forest, Adaboost и др.), демонстрируют высокую точность, однако их решения трудно интерпретировать, что ограничивает практическое применение в клинической практике. В работе предложен альтернативный подход, основанный на использовании якорных объектов (прецедентов) и локальных метрик, позволяющий построить минимальную, полностью интерпретируемую модель. На открытой выборке из 383 пациентов (108 рецидивов) сначала были случайным образом отобраны 40 якорей (по 20 из каждого класса), вычислены расстояния до них в построенных локальных метриках, а затем с помощью алгоритма извлечения логических правил JRip получено компактное решение: всего три правила на основе расстояний до четырёх якорных объектов. Модель достигает 97,13 % точности при 10-кратной стратифицированной кросс-валидации, превосходя Random Forest (96,34 % в наших экспериментах и 95,7 % в литературе), при этом сохраняя полную прозрачность: каждое правило допускает прямую клиническую интерпретацию.

Ключевые слова: рак щитовидной железы, рецидив, интерпретируемое машинное обучение, якорные прецеденты, локальные метрики, извлечение логических правил, ILMR.

1. Введение

Рак щитовидной железы – наиболее распространённая злокачественная опухоль эндокринной системы, составляющая около 1 % всех онкологических заболеваний и преобладающая среди женщин (75 % случаев) [1]. Несмотря на высокую излечивость при дифференцированной форме (WDTC), риск рецидива остаётся значимым: по данным ESMO Clinical Practice Guidelines, он достигает 15–30 % в течение 10 лет наблюдения [2]. В клинической практике для стратификации риска применяются глобальные шкалы, такие как ATA Risk Stratification, основанные на TNM-стадировании, гистологии и ответе на терапию. Однако такие шкалы построены на популяционных усреднениях и могут не учитывать редкие, но критичные клинические подтипы – например, пациентов с формально низким риском, но агрессивным течением [3].

В последние годы для повышения точности прогноза активно используются методы машинного обучения. В работе [4] на выборке из 383 пациентов (108 рецидивов) Random Forest и Adaboost достигли точности 95,7 % и 94,0 % соответственно при однократном holdout-разбиении (70/30). Аналогичный результат – заявленные 100 % точности – получен в [5] после отбора признаков, что, вероятно, указывает на переобучение. Наиболее надёжную оценку дал [6]: на независимой когорте из 542 пациентов при 5-кратной кросс-валидации Random Forest достиг 96,5 % точности и $AUC = 0,983$.

Однако, несмотря на высокую эффективность, все перечисленные работы ограничиваются глобальной интерпретируемостью: анализ сводится к важности признаков (Response, Risk, Node, Tumor, Age) или SHAP-значениям. Такой подход позволяет выделить «важные факторы», но не позволяет сформулировать реальное клиническое правило, понятное врачу. Более того, усреднённые веса признаков могут скрывать контекстно-зависимые паттерны. Например, в данных [4] диффузный зоб наблюдается у 7 пациентов без рецидива и ни у одного из 108 пациентов с рецидивом – факт, указывающий на его потенциальную прогностическую ценность как «отрицательного маркера», однако он не входит в топ-5 биомаркеров, выделенных Random Forest.

Альтернативу «признаковому» взгляду представляют прецедентные (case-based) подходы, где решение основывается на схожести с ключевыми клиническими случаями [7]. Однако большинство существующих систем используют фиксированные метрики (например, расстояние Гауэра), не учитывающие неоднородность данных: один и тот же признак может иметь разный вес в зависимости от локальной структуры класса [8].

В настоящей работе описывается результат применения усовершенствованного прецедентного подхода. Предлагаемое усовершенствование заключается в построении контекстно-зависимых локальных метрик, где веса признаков определяются отдельно для выбранных якорных объектов. Впервые применение локальных контекстно-зависимых метрик было предложено автором в середине 90-х годов [9–12]. С тех пор подход развивался и нашел применение в самых различных областях, в том числе в медицине. В данной статье, как будет показано ниже, за счет такого подхода, реализованного в методе ILMR (Iterative Local Metric Regression), удастся создавать минимальные, полностью интерпретируемые модели на основе сильных клинических прецедентов.

2. Материалы и методы

2.1. Данные

В работе использован открытый датасет, представленный в UCI Machine Learning Repository [6], описывающий 383 пациента с дифференцированным раком щитовидной железы: 275 без рецидива и 108 с рецидивом (28,2 %). Данные включают 16 клинико-патологических признаков (таб. 1), соответствующих стандартам AJCC/UICC (8-е издание) и ATA Risk Stratification [2, 3].

Состав признаков:

- демографические: возраст, пол;
- анамнестические: курение, лучевая терапия в анамнезе;
- клинические: тип зоба (диффузный, одно-/многоузловой), характер лимфаденопатии;

- патологические: гистологический тип (папиллярный, фолликулярный, гюртлевидный), очаговость, TNM-стадия, общая стадия (I–IVB);
- динамические: стратификация риска (Low/Intermediate/High), ответ на терапию (Excellent, Indeterminate, Biochemical/Structural Incomplete);
- целевая переменная: факт рецидива (Yes/No).

Данные не содержат пропущенных значений и используются без дополнительного исключения наблюдений.

Таб. 1. Переменные датасета

Переменная	Тип	Описание (кратко)
Age	Количеств.	Возраст на момент диагноза
Gender	Категор.	Пол (M/F)
Smoking, Hx Smoking, Hx Radiotherapy	Бинарн.	Актуальный статус и анамнез
Thyroid Function	Категор.	Эутиреоз, клинич./субклинич. гипер-/гипотиреоз
Physical Examination	Категор.	Тип зоба (одно/многоузловой и др.)
Adenopathy	Категор.	Характер лимфаденопатии
Pathology	Категор.	Гистологический тип (папиллярный, фолликулярный, оксифильный и др.)
Focality	Бинарн.	Очаговость (одно/многоочаговая)
Risk	Категор.	Стратификация риска по АТА (низкий/промеж./высокий)
Tumor (T), Node (N), Metastasis (M)	Порядков. / Бинарн.	Стадия по TNM, 8-е издание
Stage	Порядков.	Общая стадия (I–IVB)
Response	Категор.	Ответ на терапию (Excellent, Indeterminate, Biochemical/Structural Incomplete)
Recurred	Целевая (бинарн.)	Рецидив (Yes/No)

2.2. Методы для сравнения

Для сравнения эффективности предложенного подхода, который будет рассмотрен в следующем разделе, в исходном пространстве признаков были протестированы следующие алгоритмы машинного обучения из пакета WEKA 3.8 (настройки по умолчанию, если не указано иное):

1. Наивный байесовский классификатор (Naive Bayes) – вероятностная модель, основанная на предположении условной независимости признаков при заданном классе.
2. Логистическая регрессия (Logistic Regression) – линейный классификатор, оценивающий вероятность принадлежности к классу через логистическую функцию; использовалась с L2-регуляризацией (параметр ridge = 1e-8).
3. Метод опорных векторов (SMO) – реализация SVM с последовательной минимальной оптимизацией; применялось ядро RBF (gamma = 0.01), параметр C = 1.0.
4. Метод k ближайших соседей (IBk) – классификация по голосованию ближайших прецедентов; значение k подбиралось по кросс-валидации на тренировочной части блока (k = 1, 3, 5, 7), выбиралось оптимальное по F1-критерию.

5. Дерево решений (J48) – реализация алгоритма C4.5 с обрезкой дерева для снижения переобучения (confidenceFactor = 0.25, minNumObj = 2).
6. Случайный лес (RandomForest) – ансамбль из 100 деревьев, обученных на случайных подмножествах признаков и объектов.
7. Алгоритмы извлечения логических правил: Этим алгоритмам уделено специальное внимание, поскольку они хорошо соответствуют структуре данных в локальных метриках. Анализ распределений расстояний до якорей показал, что информативными являются как ближние ($d \approx 0$), так и удалённые ($d \geq \tau$) зоны: близость к якорю-рецидиву часто означает идентичность по ключевым признакам, удалённость от якорей-ремиссии указывает на отличие по критическим маркерам. Логические правила способны эффективно использовать оба типа условий ($\ll \tau$ и $\gg \tau$) и формировать минимальные, высокоточные правила. Из довольно большого арсенала алгоритмов поиска логических правил в данных в нашем случае были использованы следующие:
 - JRip – Repeated Incremental Pruning to Produce Error Reduction (RIPPER), формирующий компактный набор правил вида «если условие_1 $\wedge$ условие_2 $\rightarrow$ класс».
 - OneR (One Rule) – самый простой алгоритм построения классификатора на основе единственного признака. Для каждого признака формируются правила вида «если значение $\in$ интервал / категория $\rightarrow$ класс», выбирается тот признак, который даёт минимальную ошибку на обучающей выборке, и строится окончательное правило. OneR служит важной базовой моделью, демонстрирующей, насколько информативен отдельный признак в задаче классификации. Несмотря на минимальную сложность, в ряде задач (особенно при наличии доминирующего сигнала) OneR достигает точности, сопоставимой с ансамблевыми методами.

Все модели обучались и оценивались в рамках единой схемы – 10-кратной стратифицированной кросс-валидации, что обеспечивает сопоставимость результатов и устойчивость оценок.

2.3. Метод ILMR (Iterative Local Metric Regression)

Рассматривается объект-якорь $\mathbf{x}^{(t)} \in \mathbb{R}^M$ из класса c . Требуется найти вектор неотрицательных весов признаков

$$\mathbf{w}^{(t)} = (w_1^{(t)}, \dots, w_M^{(t)})^\top, \quad w_j^{(t)} \geq 0, \quad (1)$$

определяющий локальную метрику

$$\rho^{(t)}(\mathbf{x}) = \sum_{j=1}^M w_j^{(t)} \cdot (x_j - x_j^{(t)})^2. \quad (2)$$

Для каждого объекта $\mathbf{x}^{(i)}$ вводится вектор

$$\mathbf{z}^{(i,t)} = (|x_1^{(i)} - x_1^{(t)}|, \dots, |x_M^{(i)} - x_M^{(t)}|)^\top \in \mathbb{R}_{\geq 0}^M. \quad (3)$$

Целевые значения определяются бинарно:

$$y_i = \begin{cases} 0, & c_i = c, \\ 1, & c_i \neq c. \end{cases} \quad (4)$$

На итерации $s + 1$ решается задача неотрицательной взвешенной регрессии, дополненная взвешиванием анализируемых объектов:

$$\min_{\mathbf{w} \geq 0} \sum_{i=1}^N \omega_i^{(s)} \cdot (\mathbf{w}^\top \mathbf{z}^{(i,t)} - y_i)^2. \quad (5)$$

где $\omega_i^{(s)}$ – вес объекта $\mathbf{x}^{(i)}$ на итерации s (на первой итерации все веса $\omega_i^{(1)}$ устанавливаются равномерно внутри каждого класса, и сразу же нормируются до суммы 1 в каждом классе – то есть соблюдается балансировка до первой регрессии).

Обозначим текущее предсказание:

$$y_i^{\text{pred},(s)} = (\mathbf{w}^{(s-1)})^\top \mathbf{z}^{(i,t)}. \quad (6)$$

Среднее предсказание по целевому классу:

$$\mu_c^{(s)} = \frac{1}{|C_c|} \sum_{i \in C_c} y_i^{\text{pred},(s)}. \quad (7)$$

Вес для объектов своего класса ($c_i = c$)

$$\omega_i^{(s)} = \exp\left(-\frac{y_i^{\text{pred},(s)}}{\sigma}\right). \quad (8)$$

Вес для объектов чужих классов ($c_i \neq c$)

$$\omega_i^{(s)} = \begin{cases} 1, & y_i^{\text{pred},(s)} < \mu_c^{(s)}, \\ \exp\left(-\frac{y_i^{\text{pred},(s)} - \mu_c^{(s)}}{\tau}\right), & y_i^{\text{pred},(s)} \geq \mu_c^{(s)}. \end{cases} \quad (9)$$

Для компенсации дисбаланса веса нормируются отдельно внутри классов на каждой итерации:

$$\sum_{i: c_i=c} \omega_i^{(s)} = 1, \quad \sum_{i: c_i \neq c} \omega_i^{(s)} = 1. \quad (10)$$

Задача взвешенной неотрицательной регрессии на каждой итерации решается методом Лоусона–Хансона (NNLS) [13] или эквивалентным численным методом, например методом покоординатного спуска [14].

Итерационный процесс продолжается до выполнения критерия сходимости:

$$\|\mathbf{w}^{(s)} - \mathbf{w}^{(s-1)}\|_\infty < \varepsilon. \quad (11)$$

Полученный вектор $\mathbf{w}^{(t)}$ задаёт локальную метрическую функцию $\rho^{(t)}$, обеспечивающую концентрацию объектов целевого класса в окрестности якоря $\mathbf{x}^{(t)}$.

В целом, основные свойства алгоритма ILMR следующие:

1. Вычислительная эффективность – ILMR требует на 1–2 порядка меньше ресурсов, чем стохастические методы (например, генетический алгоритм).
2. Разреженность и интерпретируемость – даже без регуляризации достигается 70–80% обнуления весов; L1-модификация усиливает этот эффект.
3. Детерминированность – гарантирует воспроизводимость результатов.
4. Устойчивость к шуму и дисбалансу классов – за счёт адаптивного взвешивания и балансировки.

Таким образом, ILMR представляет собой практичную альтернативу для задач, где важны скорость, интерпретируемость и устойчивость (не только в медицинских системах поддержки решений).

2.3.1. Иллюстрация метода ILMR

В отличие от глобальных методов машинного обучения, таких как Random Forest, которые оценивают важность признаков в среднем по всей выборке (например, «признак Response является наиболее значимым для прогнозирования рецидива»), метод ILMR оперирует уровнями признаков, предварительно закодированными с помощью one-hot-представления*. Это позволяет присвоить индивидуальные веса каждому конкретному значению (например, «Structural Incomplete» vs «Excellent»), даже если они принадлежат одному и тому же исходному признаку. Таким образом, локальная метрика отражает не «важность признака», а важность конкретного клинического паттерна, характерного для данного пациента-якоря.

В качестве примера рассмотрим якорь Obj242 – пациент с рецидивом. Для пациента Obj242 метод ILMR выявил у пациента Obj242 компактный паттерн из четырёх независимых признаков, обеспечивающий точность 94.7 % в прогнозировании рецидива (чувствительность 88.9 %, специфичность 96.4 %). Результат представлен в двух эквивалентных форматах (табл. 2): техническом (отражающем работу алгоритма) и клиническом (ориентированном на практикующего врача).

Таб. 2. Локальная метрика для якоря 242 (рецидив): два эквивалентных представления

Признак	Техническое представление (Level ILMR)	Клиническое представление	Вес	Вклад, %
Response	Structural Incomplete	Structural Incomplete	0.54	77.91
Pathology	HE Hurthel cell	Papillary, Follicular, Poorly differentiated	0.08	11.6
Physical Examination	HE Normal	Single/Multinodular goiter	0.042	6.02
Thyroid Function	HE Clinical Hyperthyroidism	Euthyroid / Suspected Hyper / Hypothyroid	0.03	4.47

Примечание. Техническое представление отражает логику one-hot-кодирования: «Level» – совпадение с якорём, «HE Level» – расхождение. Клиническое представление эквивалентно ему, но формулируется в терминах наличия признаков, принятых в протоколах АТА и клинической практике.

На рис. 1 представлены диаграммы рассеяния расстояний объектов от якоря 242 в общем пространстве признаков и с использованием локальной метрики.

* Заметим, что в ILMR номинальные признаки кодируются по схеме one-hot, так что каждый уровень становится независимой координатой в признаковом пространстве.




Рис. 1. Сравнение распределения классов в а) исходной (Gower) и б) локальной (ILMR) метриках для якоря Obj242

Клиническая интерпретация компонентов:

1. Structural Incomplete Response (77.9 %) – доминирующий маркер, который указывает на сохранение структурной болезни после терапии (видео/УЗ-визуализируемый остаток), что по классификации ATA [2015] относится к группе высокого риска. ILMR подтверждает: этот признак вносит наибольший вклад – но не сам по себе, а в сочетании с другими характеристиками.

2. Не-Hurthle гистология (11.6 %) – ключевое уточнение. Пациент имеет папиллярную, фолликулярную или слабодифференцированную карциному – подтипы, составляющие >85 % РДРЩЖ. Высокий вес HE Hurthle cell означает, что пациенты с Hurthle-клеточной опухолью лежат «далеко» от паттерна 242 – их риск формируется иначе. Это согласуется с данными о том, что Hurthle-опухоли, несмотря на агрессивность, часто сохраняют захват йода и могут лучше отвечать на RAI.

3. Пальпируемый узел (6.0 %) – локальный фактор.

HE Normal в физикальном осмотре означает наличие одиночного или многоузлового зоба – признак, усиливающий подозрение на агрессивное течение при уже структурно неполном ответе.

4. Не-гипертиреоидный статус (4.5 %) – системный маркер.

Отсутствие клинического гипертиреоза (эутиреоз, подозрение на гипер- или гипотиреоз) может отражать:

- менее дифференцированную опухоль с пониженной продукцией тиреоглобулина,
- или метаболически «тихое» течение, ускользающее от стандартного мониторинга.

На основе паттерна сформулировано интерпретируемое OneR-правило:

«Если у пациента Structural Incomplete Response, не-Hurthle гистология, пальпируемый узел и отсутствие клинического гипертиреоза – прогнозируется рецидив с вероятностью >94 %».

Это правило, во-первых, уточняет рекомендации ATA (которые не учитывают взаимодействие гистологии и функционального статуса). И, во-вторых, может быть непосредственно использовано в СППР как локальный триггер усиленного наблюдения.

В целом, паттерн 242 демонстрирует парадигму персонализированного ИИ в медицине: вместо поиска единой «лучшей модели» мы выявляем локальные законы, действующие в окрестности конкретного случая. При этом техническая строгость (ILMR + ILM-фильтр) и клиническая естественность (перевод в язык практики) дополняют друг друга. Такой подход соответствует

принципу «объяснимости через релевантность»: объяснение ценно не потому, что оно «простое», а потому, что оно восстанавливает клинически значимые закономерности, упущенные глобальными методами.

3. Результаты

На выборке из 383 пациентов (108 рецидивов) с использованием 10-кратной стратифицированной кросс-валидации протестированы 8 стандартных методов машинного обучения и гибридный подход ILMR + OneR и ILMR + JRip, упомянутых в п. 2.2. Наибольшую точность среди классических методов показал Random Forest: 96,34 % (табл. 3), что согласуется с литературными данными (95,7 % [4], 96,5 % [6]). Однако наибольшая точность – 97,13 % – была достигнута моделью из трёх правил, сгенерированной алгоритмом ILMR + JRip в пространстве локальных расстояний:

$$\begin{aligned} & (Anchor_{324} \leq 0.2919) \rightarrow Class = Yes \ (90.0/1.0) \\ & (Anchor_{148} \geq 0.4667) \wedge (Anchor_{329} \geq 0.4896) \wedge (Anchor_{8} \geq 0.3896) \\ & \quad \rightarrow Class = Yes(3.0/0.0) \\ & \text{иначе} \rightarrow Class = No \ (280.0/7.0) \end{aligned}$$

Таб. 3. Сравнение методов машинного обучения (10-CV)

Метод	Точность	Чувствительность (Yes)	Специфичность (No)	Интерпретируемость
Наивный Байес	91.38 %	85.2 %	93.8 %	Низкая (вероятности)
Логистическая регрессия	96.08 %	89.8 %	98.5 %	Средняя (веса признаков)
SVM (SMO)	95.56 %	90.7 %	97.5 %	Низкая (граница решений)
k-NN (k=7)	92.95 %	80.6 %	97.8 %	Средняя (ближайшие случаи)
J48 (дерево)	94.78 %	87.0 %	97.8 %	Высокая (ветви дерева)
PART (правила)	94.78 %	88.9 %	97.1 %	Высокая (правила)
JRip	93.99 %	87.0 %	96.7 %	Высокая (правил)
Random Forest	96.34 %	89.8 %	98.9 %	Низкая
ILMR + OneR	96.87 %	90.7 %	99.3 %	Максимальная
ILMR + JRip	97.13 %	91.7 %	99.3 %	Максимальная

Ключевое наблюдение: первое правило покрывает 90 объектов с одной ошибкой точность – 98.9 %), обеспечивая основной вклад в точность и интерпретируемость. Оно выделяет пациентов, близких к прецеденту Anchor_324 – пациенту с *диффузным зобом, гюртлевидной клеткой и неполным структурным ответом при промежуточном АТА-риске*, но с подтверждённым рецидивом.

Заметим, что даже однопризнаковая модель OneR, обученная на расстояниях до 40 якорей, достигает 96,87 % точности, отбирая в качестве единственного предиктора Anchor_324 – тот же

сильный прецедент, что лежит в основе первого правила JRip. Это дополнительно подтверждает, что Anchor_324 является доминирующим клиническим паттерном в данных.

В локальной метрике Anchor_324 вес уровня Structural Incomplete составляет 0.987, а Diffuse goiter – 0.248 – оба значимо выше среднего. Это означает, что правило $\text{Anchor_324} \leq 0.2919$ не является статистическим приближением, а отражает логически строгий паттерн: при расстоянии = 0 пациент полностью совпадает с Anchor_324 по этим уровням, и все такие пациенты имели рецидив.

Второе правило, сгенерированное JRip, повышает общую точность с 94.78 % до 97.13 %, но охватывает лишь 3 дополнительных пациента и состоит из комбинации условий на расстояния до трёх якорей-ремиссий. С клинической точки зрения оно не допускает прямой интерпретации и служит скорее техническим уточнением, чем самостоятельным диагностическим правилом.

Таким образом, модель можно представить в двух режимах:

- Максимальная точность – 3 правила (точность 97.13 %, чувствительность 91.7 %);
- Максимальная интерпретируемость – 1 правило (точность 94.78 %, чувствительность 82.4 %), где каждое решение верифицируется вручную.

4. Обсуждение

Современные системы поддержки решений в онкологии часто опираются на глобальные модели, где интерпретация сводится к «важности признаков» (например, *Response, Risk, Node* [4]). Однако такой подход имеет принципиальное ограничение: он усредняет влияние всех уровней признака, игнорируя контекстно-зависимые паттерны. Пример: в данных [4] (табл. 2) *диффузный зоб* встречается у 7 пациентов без рецидива и ни у одного из 108 пациентов с рецидивом. Это сильный кандидат на «отрицательный маркер» – но в глобальной модели он «растворяется» в категориальной переменной *Physical Examination*, включающей также *multinodular* и *single nodule*.

ILMR решает эту проблему: он не усредняет, а дифференцирует. Для Anchor_324 вес уровня Diffuse goiter – 0.248 (в 5 раз выше среднего), и он входит в ядро локальной метрики. Правило $\text{Anchor_324} \leq 0.2919$ становится не просто «статистическим сигналом», а реальным клиническим правилом:

«Если пациент близок к случаю с диффузным зобом, гортелевидной клеткой и неполным структурным ответом – даже при промежуточном АТА-риске – риск рецидива превышает 98 %».

Это правило, с одной стороны, верифицируемо вручную – достаточно сравнить профиль пациента с историей Anchor_324. С другой – обсуждается на консилиуме – оно формулируется на языке клинических категорий, а не SHAP-значений. Также это правило можно использовать для обучения резидентов редким, но критичным подтипам.

Второе правило модели (на 3 якорях-ремиссиях) формально повышает точность, но его сложная структура и низкое покрытие делают его малоприменимым для клинического использования. Мы рассматриваем его как методологический артефакт алгоритма RIPPER, стремящегося к максимальному покрытию без ограничения на минимальное число случаев. В будущем планируется его замена на правило с порогом более высоким порогом покрытия, что повысит клиническую репрезентативность без потери точности.

Важно подчеркнуть: ILMR не отвергает глобальные модели – он дополняет их.

- Random Forest отвечает на вопрос: «Какие признаки в среднем важны для прогноза?»
- ILMR+JRip отвечает на вопрос: «На какого конкретного пациента похож мой случай – и какой у него был исход?»

Такой переход от популяционной к прецедентной логике особенно ценен в персонализированной онкологии, где рекомендации, основанные на «среднем пациенте», могут быть неадекватны для конкретного человека.

5. Заключение

В работе эмпирически показано, что интерпретируемость и точность не противоречат друг другу при условии, что интерпретируемость строится не на постфактум-аппроксимации, а на

структуре самой модели. Предложенный подход – ILMR в сочетании с извлечением логических правил – позволяет:

1. Выделить сильные клинические прецеденты (например, Anchor_324), где веса присваиваются не признакам, а конкретным уровням в контексте данного случая;
2. Сформировать минимальные, верифицируемые правила, такие как $\text{Anchor_324} \leq 0.2919 \rightarrow$ рецидив, где каждое условие допускает прямую проверку по истории болезни;
3. Сохранить гибкость: использовать одно правило для максимальной прозрачности или дополнительные – для повышения чувствительности.

Модель из одного правила достигает 94.78 % точности и 82.4 % чувствительности при 99.6 % специфичности – показатели, достаточные для клинического скрининга и принятия решений в условиях высокой неопределённости. При этом она не требует доверия к модели, а опирается на логическое сходство с известными прецедентами – то, что соответствует естественной клинической практике. Таким образом, ILMR предлагает не альтернативу современным методам машинного обучения, а интерфейс между ИИ и врачом – где главное не «насколько точно предсказано», а «на чём основано решение – и согласен ли с ним клиницист после проверки».

Финансирование

Работа выполнена в рамках исполнения государственного задания ИПТ РАН № 075-00605-26-00 на 2026 год и плановый период 2027 и 2028 годов за счет средств предоставленной Минобрнауки России субсидии (соглашение о предоставлении субсидии из федерального бюджета на финансовое обеспечение выполнения государственного задания от 20.01.2026 № 075-03-2026-498).

3. Литература

- [1] Siegel R. L. et al. Cancer statistics, 2023 //CA: a cancer journal for clinicians. – 2023. – Т. 73. – №. 1.
- [2] Filetti S. et al. Thyroid cancer: ESMO Clinical Practice Guidelines for diagnosis, treatment and follow-up //Annals of Oncology. – 2019. – Т. 30. – №. 12. – С. 1856-1883.
- [3] Ito Y., Onoda N., Okamoto T. The revised clinical practice guidelines on the management of thyroid tumors by the Japan Associations of Endocrine Surgeons: core questions and recommendations for treatments of thyroid cancer //Endocrine journal. – 2020. – Т. 67. – №. 7. – С. 669-717.
- [4] Yaşar Ş. Determination of possible biomarkers for predicting well-differentiated thyroid cancer recurrence by different ensemble machine learning methods. Mid Blac Sea J Health Sci. 2024;10(3):255–265.
- [5] Setiawan KE. Predicting recurrence in differentiated thyroid cancer: a comparative analysis of various machine learning models including ensemble methods with chi-squared feature selection. Commun Math Biol Neurosci 2024;55: 1-29.
- [6] Borzooei S. et al. Machine learning for risk stratification of thyroid cancer patients: a 15-year cohort study. Eur Arch Otorhinolaryngol. 2024; 281:2095–2104.
- [7] Aamodt A., Plaza E. Case-based reasoning: Foundational issues, methodological variations, and system approaches //AI communications. – 1994. – Т. 7. – №. 1. – С. 39-59.
- [8] Rosch E. Cognitive representations of semantic categories. J Exp Psychol Gen. 1975; 104(3):192–233.
- [9] Дюк В.А. Компьютерная психодиагностика. – СПб: Братство. – 1994. – 364 с.
- [10] Dyuk V. A. Context-dependent local metrics and a geometrical approach to the problem of knowledge formation // Izvestiya Rossiiskoi Akademii Nauk. Teoriya i Sistemy Upravleniya. – 1996. – № 5. – Р. 36–44.
- [11] Дюк В.А. Обработка данных на ПК в примерах. – СПб: "Питер", 1997. – 240 с.

- [12] Duke V. A. Latent knowledge extraction by methods of local geometry: development of expert system for keen appendicitis diagnostics // Proc. Intern. Conf. On Informatics and Control (ICI&C 97). – 1997. – P. 663–668.
- [13] Lawson C. L., Hanson R. J. Solving least squares problems. – Society for Industrial and Applied Mathematics, 1995.
- [14] Tseng P. Convergence of a block coordinate descent method for nondifferentiable minimization // Journal of optimization theory and applications. – 2001. – Т. 109. – №. 3. – С. 475-494.

Interpretable Prediction of Thyroid Cancer Recurrence Based on Anchor Local Metrics and a Minimal Rule Set

Diuk V.A.

Solomenko Institute of Transport Problems of the Russian academy of sciences

v_duke@mail.ru

Abstract. Predicting recurrence of differentiated thyroid cancer remains an important clinical challenge despite the high efficacy of modern treatment methods. Contemporary machine learning models, including ensemble algorithms (Random Forest, AdaBoost, etc.), demonstrate high accuracy; however, their decisions are difficult to interpret, which limits their practical application in clinical practice. This paper proposes an alternative approach based on anchor instances (precedents) and local metrics, enabling the construction of a minimal, fully interpretable model. Using an open dataset of 383 patients (108 recurrences), 40 anchors were first randomly selected (20 from each class), distances to these anchors were computed in the constructed local metrics, and then a compact solution was obtained via the JRip logical rule extraction algorithm: merely three rules based on distances to four anchor instances. The model achieves 97.13% accuracy under 10-fold stratified cross-validation, outperforming Random Forest (96.34% in our experiments and 95.7% reported in the literature), while maintaining complete transparency: each rule allows direct clinical interpretation. The proposed approach combines high accuracy, sparsity, interpretability, and conciseness, offering an effective tool for clinical decision support.

Keywords: thyroid cancer, recurrence, interpretable machine learning, anchor instances, local metrics, logical rule extraction, ILMR.

Funding

The work was carried out within the framework of the implementation of the state assignment of the Institute of Transport Problems of the Russian Academy of Sciences No. 075-00605-26-00 for 2026 and the planning period of 2027 and 2028 at the expense of the subsidy provided by the Ministry of Education and Science of Russia (agreement on the provision of a subsidy from the federal budget for financial support for the implementation of the state assignment dated 20.01.2026 No. 075-03-2026-498).